

Detecção de Ações de Pessoas

Integração de YOLO, U-Net e SlowFast em vídeos curtos

CHECKPOINT 5	ENTREGA: 06/10/2026	CÓDIGO EXECUTÁVEL
--------------	---------------------	-------------------

Objetivo

Desenvolver um programa que localize a pessoa, segmente seus pixels e classifique a ação em janelas temporais sucessivas. Foram integrados exclusivamente modelos já treinados: YOLO11n (COCO), U2-Net Human Segmentation e SlowFast R50 (Kinetics-400).

1 YOLO pessoa e caixa	2 U-Net mascara no recorte	3 SlowFast acao por janela	4 Saida MP4 + CSV + JSON
-----------------------------	----------------------------------	----------------------------------	--------------------------------

Implementação

O YOLO filtra a classe person. A detecção principal combina confiança e área; sua caixa é expandida em 10% e enviada à U-Net. A máscara binária é redimensionada e reprojetada nas coordenadas do quadro original. O SlowFast recebe janelas de 32 quadros, com passo 16 e razão temporal $\alpha=4$. Cada quadro final reúne caixa, máscara, ação e confiança. Também são gerados CSV por quadro e JSON por janela.

Grupo e responsabilidades

Integrante	RM	Responsabilidade
Guilherme Santos	551168	Integração, testes e documentação
Enricco	551717	YOLO e leitura dos vídeos
Gabriel	99227	U-Net e projeção da máscara
Danilo	99465	SlowFast e janelas temporais
Laura	98747	Experimentos, análise e apresentação

Experimentos e resultados

Foram processados dois clipes públicos de 8 s a 8 FPS (64 quadros): arco e flecha em ambiente externo e dança em palco escuro. As amostras abaixo correspondem ao fim das três janelas temporais.


VÍDEO 1 64/64 detecções YOLO	YOLO MÉDIO 83,5% arco e flecha	VÍDEO 2 12/64 máscaras não vazias	SLOWFAST 88,8 → 75,0% dança no palco
---	---	--	---

Vídeo	Momento	YOLO	Máscara (px)	Ação SlowFast	Conf.	Avaliação
1	1 (4.0s)	83.4%	5827	archery	100.0%	correta
1	2 (5.9s)	82.2%	1936	archery	100.0%	correta
1	3 (7.9s)	86.1%	2539	archery	100.0%	correta
2	1 (4.0s)	82.2%	0 (falha)	dancing ballet	88.8%	correta
2	2 (5.9s)	83.1%	0 (falha)	dancing ballet	83.7%	correta
2	3 (7.9s)	87.5%	0 (falha)	dancing ballet	75.0%	correta

Vídeo 1 - três momentos de arco e flecha



Vídeo 2 - três momentos de dança em palco



Fonte dos clipes: exemplos públicos do projeto PyTorchVideo. As imagens mostram as saídas efetivamente produzidas nesta execução.

Análise de falhas e conclusão

Erro 1 - seleção da pessoa em cenas com múltiplos indivíduos

Nos dois vídeos há mais de uma pessoa. A heurística escolhe uma única detecção usando confiança $\times$ área; por isso, pode trocar o alvo ou preferir uma pessoa secundária. No vídeo 1, a ação continuou correta porque o contexto de arco e flecha é forte, mas a caixa nem sempre representou a pessoa mais próxima. Uma correção futura é incorporar rastreamento (ByteTrack) e manter o mesmo ID entre quadros.

Erro 2 - máscara ausente em iluminação baixa

No palco escuro, o YOLO detectou pessoa em 64/64 quadros (80,3% de confiança média), porém a U-Net produziu máscara não vazia em apenas 12/64 quadros. A baixa separação entre roupa, fundo e sombra, somada à pessoa pequena, prejudicou o contorno. Ajustar o limiar reduz falsos negativos, mas pode ampliar ruído; um checkpoint treinado no domínio do palco seria mais adequado.

Transições temporais

A classe archery permaneceu em 100% nas três janelas. No segundo vídeo, dancing ballet permaneceu correta, mas caiu de 88,8% para 83,7% e 75,0%. A queda acompanha mudança de pose e oclusão no fim do trecho, confirmando que início e término da ação afetam a confiança, mesmo quando a classe não muda.

Parecer dos integrantes

Guilherme	A integração é reproduzível; rastreamento é a melhoria prioritária.
Enricco	O YOLO foi estável, mas cenas com várias pessoas exigem identidade temporal.
Gabriel	A máscara foi boa em luz natural e falhou no palco escuro, evidenciando domínio.
Danilo	O SlowFast acertou as ações; a confiança refletiu as transições do movimento.
Laura	A sobreposição e os arquivos tabulares tornam os erros fáceis de demonstrar.

Conclusão

O pipeline cumpriu a integração solicitada e gerou vídeo, caixa, máscara, ação e confiança sem treinamento adicional. O experimento mostrou alto desempenho no cenário externo e expôs duas limitações importantes: associação do alvo em cenas com várias pessoas e segmentação em baixa iluminação. Os resultados ruins foram preservados porque explicam onde cada modelo precisa de contexto, rastreamento ou adaptação de domínio.

Código, configurações, testes, vídeo demonstrativo e evidências estão versionados no repositório do grupo.