

Detecção de ações de pessoas

Localização, contorno e ação em dois vídeos curtos. Relatório revisado com resultados reais do pipeline corrigido.

Objetivo e modelos

Integrar modelos já treinados, sem treinar ou ajustar pesos: YOLO11n (COCO, classe person), U-Net com encoder EfficientNet-B0 e decoder treinados para segmentação humana, e SlowFast R50 (Kinetics-400). A U-Net completa substitui a U²-Net utilizada na versão anterior.

Integração e cobertura temporal

O YOLO fornece as caixas. Cada região é expandida em 10%, recortada e enviada à U-Net em RGB, 320 × 320 e valores [0,1]. O sigmoid e limiar 0,5 produzem a máscara, redimensionada e reprojeta no quadro original. A seleção principal prioriza candidatos com máscara não vazia e continuidade por IoU, com confiança e área como alternativa. Isso reduz a seleção do fundo, mas não garante identidade.

O SlowFast recebe 32 quadros, passo 16 e $\alpha=4$. A última janela é fechada no último quadro, mesmo fora do passo regular. Em uma segunda passagem offline, cada quadro recebe a previsão da janela que o contém e tem o centro mais próximo. Assim a ação aparece desde o início, usando contexto temporal futuro; não se trata de processamento em tempo real. As saídas são MP4, CSV e JSON com top-3.

Execução isolada e experimentos

Cada modelo também foi executado separadamente nos dois trechos. A U-Net isolada recebe o quadro inteiro, sem YOLO; a execução integrada recebe os recortes. Foram analisados 80 e 80 quadros a 8 FPS, por 10 s. O SlowFast possui quatro janelas em cada vídeo: 0-4, 2-6, 4-8 e 6-10 s. O teste opcional usa as mesmas caixas do pipeline para comparar contexto completo e recorte.

Grupo e responsabilidades

Integrante	RM	Área / parecer técnico
Guilherme Santos	551168	Integração: cobertura completa e dados reproduzíveis são essenciais.
Enricco	551717	YOLO: várias pessoas e entrada no quadro exigem avaliar o alvo escolhido.
Gabriel	99227	U-Net: máscara não vazia não significa contorno correto; o recorte altera o resultado.
Danilo	99465	SlowFast: confiança é saída do modelo e não mede acurácia ou certeza.
Laura	98747	Análise: manter os erros permite explicar limites e comparar as janelas.

Fontes e reprodução

Vídeo 1: archery.mp4 do tutorial público PyTorchVideo (0-10 s). Vídeo 2: theatre.webm, Theatre Flamenco of San Francisco, do tutorial de detecção PyTorchVideo (1-11 s). Trechos, URLs diretas e checksums estão versionados. O checkpoint U-Net é de Aman Gupta, repositório PyTorch-Image-Segmentation, revisão d5f9ab4, licença MIT. É independente do arquivo do Teams.

Reprodução: instalar requirements-cpu.txt e executar python scripts/reproduce_cp5.py. O repositório inclui dados brutos, execuções isoladas, configuração e manifesto de ambiente.

Resultados e inspeção visual


YOLO: 80/80 quadros com pessoa no arco e flecha; 78/80 no palco. Máscara integrada não vazia: 80/80 e 33/80. Contagens indicam presença de saída, não acurácia ou qualidade de contorno.

V.	Tempo	Caixa	Máscara (px)	Ação prevista	Conf.	Inspeção visual
1	0.00s	sim	8227	archery	100.0%	Pessoa principal localizada; contorno parcial, com objetos/fundo. Preparação; ação correta.
1	5.00s	sim	6986	archery	100.0%	Caixa acompanha o arqueiro; máscara parcial. Mira; ação correta.
1	9.88s	sim	3617	archery	100.0%	Caixa estável; parte do corpo fora do quadro e máscara incompleta. Recuperação; classe permanece.
2	0.00s	não	0	tango dancing	32.2%	Pessoa parcial e borrada; caixa e máscara ausentes. Tango aproxima dança, sem acertar o gênero.
2	5.00s	sim	718	giving or receiving award	29.5%	Bailarina localizada; máscara cobre só parte do contorno. A classe award é um erro.
2	9.88s	não	0	tango dancing	69.6%	Seleciona participante ao fundo, não a bailarina. Máscara ausente; tango não é flamenco.

Vídeo 1: preparação (0 s), mira (5 s) e recuperação após disparo (9,88 s)



Vídeo 2: entrada parcial/borrada, dança no meio do trecho e seleção do fundo



A caixa acompanha o arqueiro selecionado, embora extremidades fiquem fora do quadro. A máscara cobre o corpo apenas parcialmente e inclui objetos ou fundo. No palco, a seleção melhora em parte do trecho, mas volta a uma pessoa ao fundo quando nenhum candidato é segmentável.

A ação observada no vídeo 2 é dança de flamenco. Tango é uma aproximação do gênero; giving or receiving award não corresponde à ação observada. Flamenco não aparece como classe específica no vocabulário Kinetics-400 utilizado. Não foram calculados IoU/Dice ou acurácia: não há máscaras de referência nem anotações completas dos vídeos.

Erros, transições e comparação

Erro 1 - associação do alvo e falha de segmentação

No palco, a seleção pode persistir em um participante ao fundo, e a máscara integrada é não vazia em 33/80 quadros. A U-Net isolada produz máscara em 79/80, o que impede atribuir a falha apenas à iluminação. A seleção do alvo, a escala e a deformação do recorte também interferem. Priorizar máscaras válidas melhora parte do trecho, mas não substitui rastreamento com identidade.

Erro 2 - classe incompatível no palco

Na janela 4-8 s, o SlowFast prevê giving or receiving award, apesar de a pessoa continuar dançando. Outras janelas retornam tango dancing, que não identifica corretamente o flamenco. Contexto de palco, mudança de pose e vocabulário limitado são hipóteses explicativas; não foi feita intervenção controlada para provar a causa. Aumentar a confiança não corrige automaticamente a classe.

Início, execução e término: a confiança cai ou a classe muda?

No arco e flecha, preparação, mira e recuperação após disparo aparecem no trecho. A classe permanece archery e a confiança fica em 100% nas quatro janelas, inclusive na janela final: não há queda observada ou troca de classe nas fases visuais. Isso mostra que uma janela pode conservar contexto da ação anterior. No palco, há movimento contínuo; o trecho não documenta um início ou término completo do flamenco. A classe muda mesmo assim, portanto essa mudança não pode ser apresentada como prova de início ou fim.

Janela (s)	Arco e flecha	Palco: classe / confiança
0-4	archery / 100.0%	tango dancing / 32.2%
2-6	archery / 100.0%	tango dancing / 55.3%
4-8	archery / 100.0%	giving or receiving award / 29.5%
6-10	archery / 100.0%	tango dancing / 69.6%

Extensão opcional - quadro e recorte

Vídeo / janela	Quadro inteiro	Recorte da pessoa
V1 / 0-4s	archery / 100.0%	archery / 100.0%
V1 / 2-6s	archery / 100.0%	archery / 100.0%
V1 / 4-8s	archery / 100.0%	archery / 100.0%
V1 / 6-10s	archery / 100.0%	archery / 100.0%
V2 / 0-4s	tango dancing / 32.2%	tango dancing / 42.3%
V2 / 2-6s	tango dancing / 55.3%	tango dancing / 74.5%
V2 / 4-8s	giving or receiving award / 29.5%	tango dancing / 48.4%
V2 / 6-10s	tango dancing / 69.6%	tango dancing / 71.3%

O recorte usa a união das caixas da mesma janela. Pode reduzir contexto ou incluir o alvo incorreto; a comparação não prova que recortar sempre melhora o reconhecimento.

Conclusão

Os três modelos pré-treinados foram integrados e executados isoladamente, sem treinamento adicional. A demonstração conserva caixa, máscara, ação e confiança, inclusive resultados ruins. O relatório responde às diferenças de localização, contorno e classe nos seis momentos; CSV, JSON, vídeos e scripts permitem inspecionar as conclusões. Os pareceres técnicos do grupo devem ser revisados pelos integrantes antes da entrega.